Agentes

SESIÓN 02
IA GENERATIVA / LLM

AGENDA

01 Framwork

02 Langchain

03 Base de Datos Vectorial

04 RAG

Framework

LangChain
LlamaIndex
Hugging Face Transformes
Haystack
vLLM
FastChat
OpenLLM
Text Generation Inference
Axolotl

Langchain

Es un framework que se creó en octubre 2022, para simplificar la creación de aplicaciones basada en LLM, su creador es Harrison Chase.

Se puede usar con Python y Javascript.

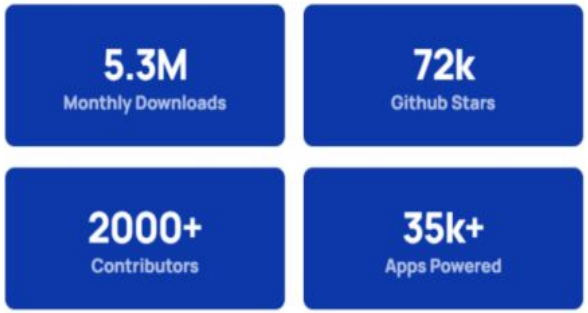

Langchain - LLM

Langchain tiene integración con múltiples LLM.

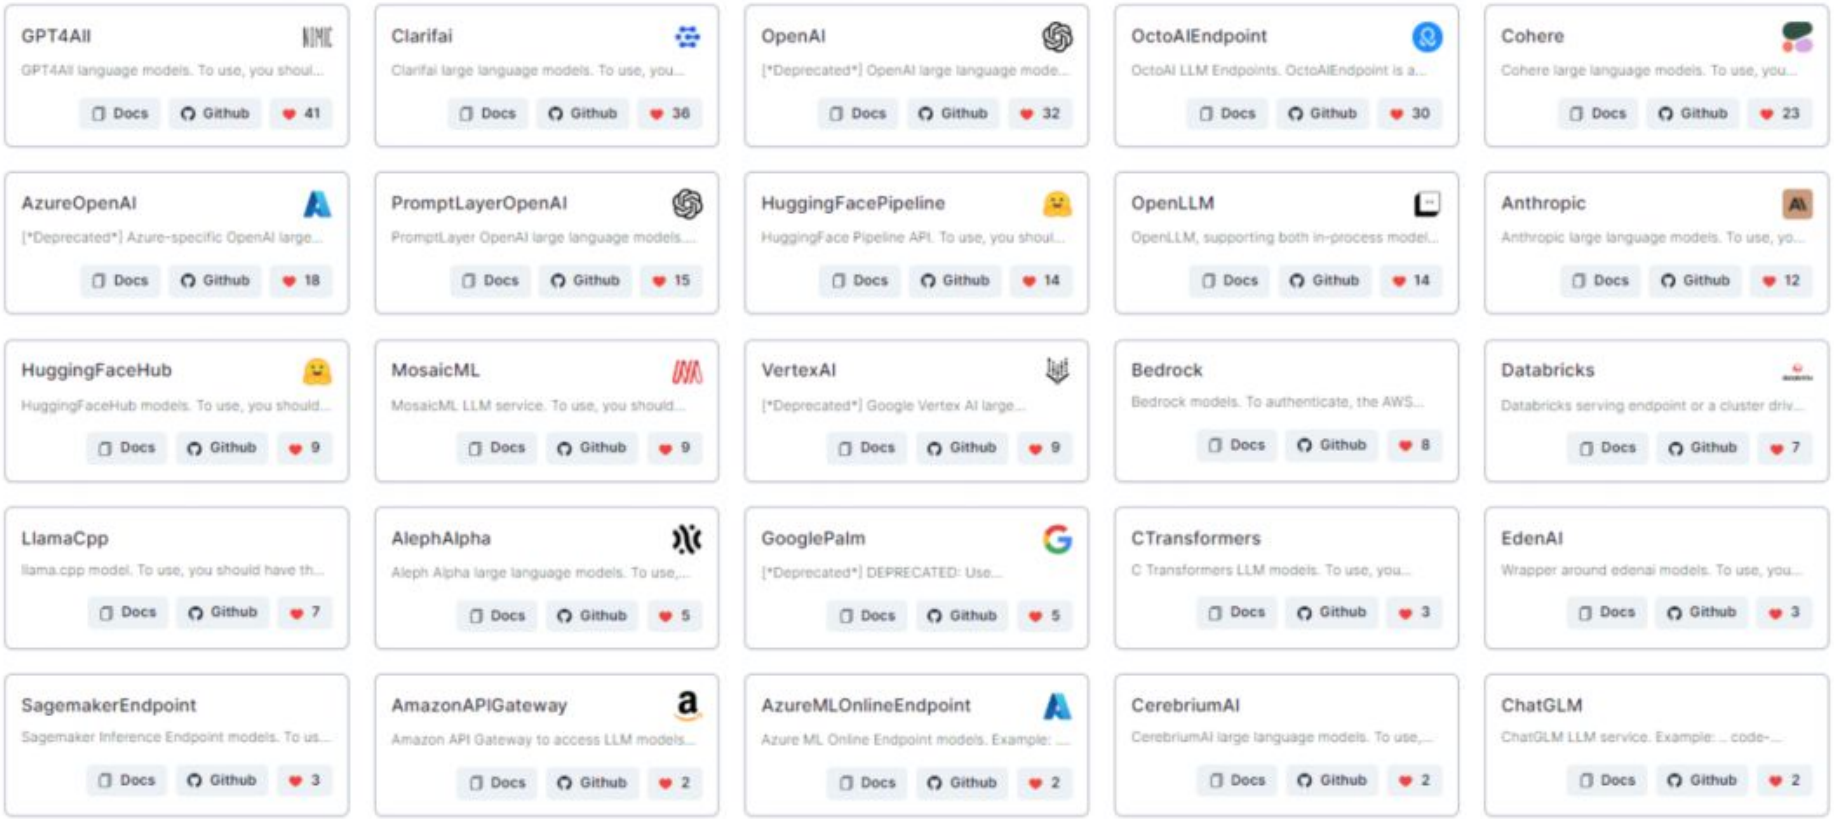

https://docs.langchain.com/langsmith/integrations

Langchain - Memory

La mayoría de las aplicaciones LLM tienen una interfaz conversacional.
Un componente esencial de una conversación es poder hacer referencia a la información presentada anteriormente en la conversación, en Langchain se puede almacenar conversaciones en memoria.

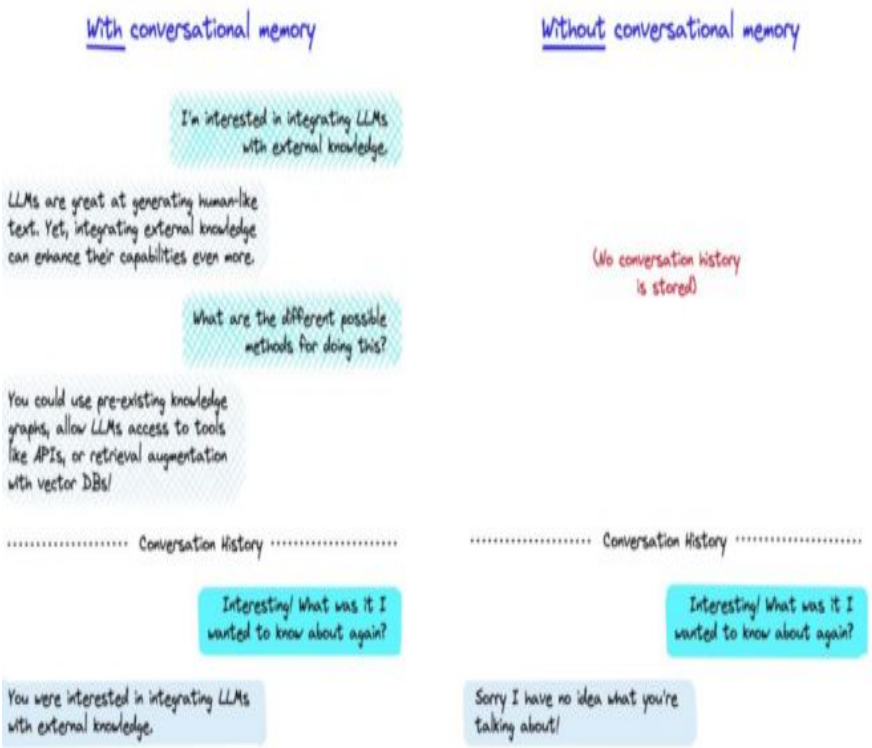

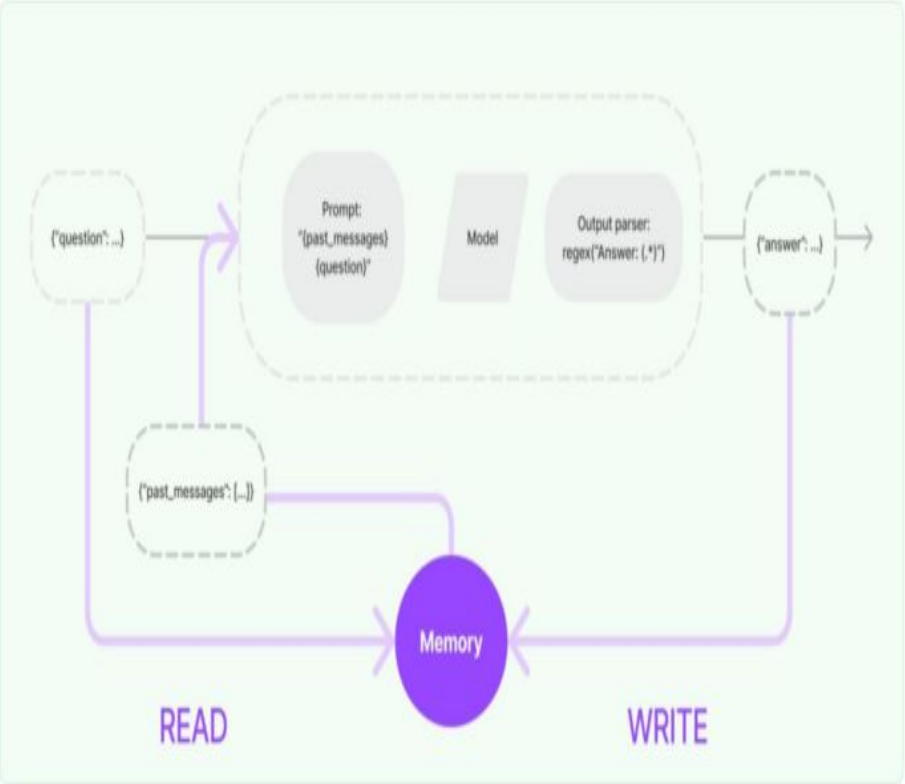

Langchain - Document Loaders

Los Document Loader proporcionan un método de ingesta para cargar datos como documentos desde una fuente que puede ser un PDF, csv, videos de youtube, archivos en S3, Slack, website, etc. Se usan estos documentos para múltiples propósitos en los cuales destacan la carga de datos a una base de conocimiento (Base de datos vectorial).
En LangChain, un Documento es una estructura con dos campos:

- page_content : Este campo contiene el texto sin formato del documento.
- metadata : Este campo almacena metadatos adicionales sobre el texto, como la URL de origen, el autor o cualquier otra información relevante.

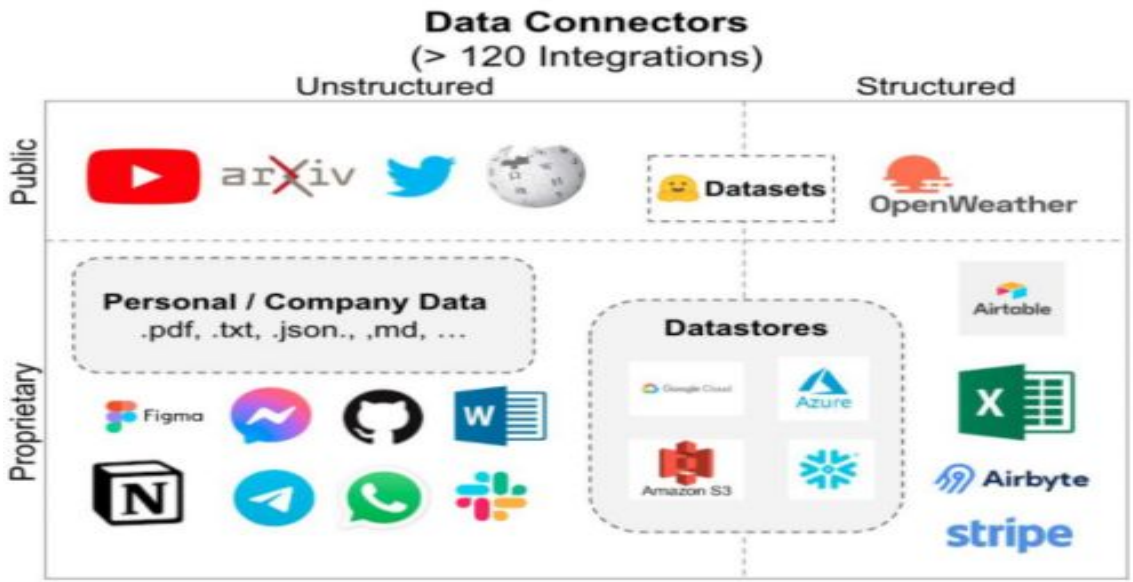

https://python.langchain.com/docs/integrations/document_loaders/

Langchain - Document Transformers

Una vez que se cargan los documentos, se deben transformar para que se adapten mejor a su aplicación. El ejemplo más simple es que desee dividir un documento largo en partes más pequeñas que puedan entrar en la ventana contextual de su modelo (máximo de tokens en el prompt permitido por un LLM).
LangChain tiene una serie de transformadores de documentos integrados que facilitan la división de documentos.

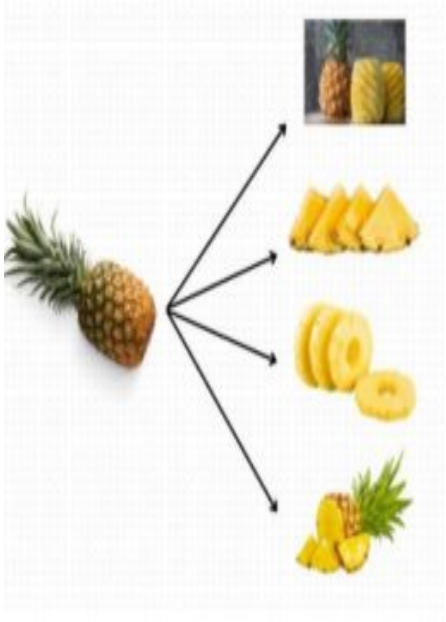

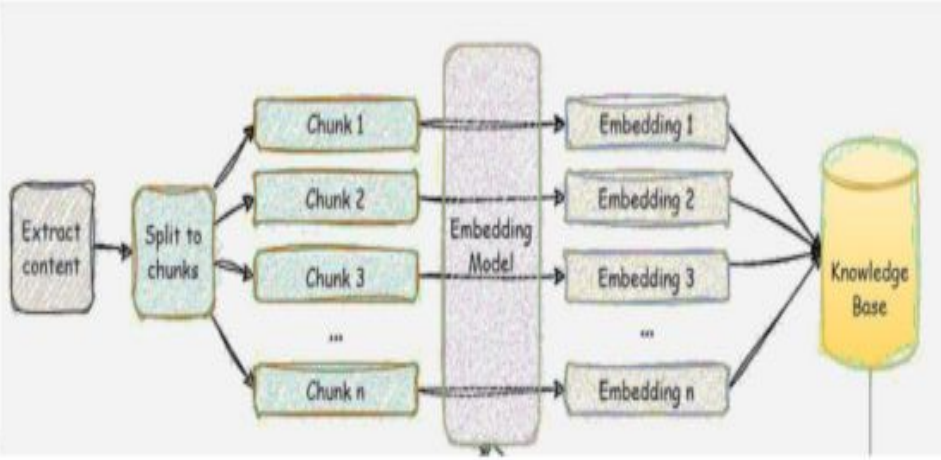

Langchain - Document Transformers

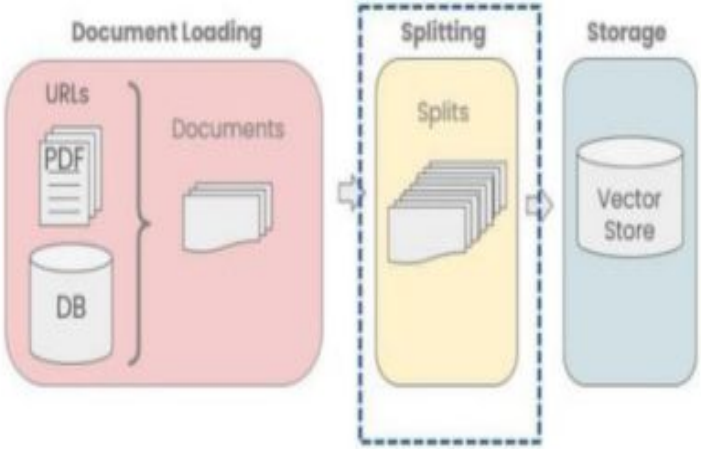


```python
from langchain.text_splitter import CharacterTextSplitter

text_splitter = CharacterTextSplitter.from_tiktoken_encoder(
    chunk_size = 400,
    chunk_overlap = 20
)

docs = text_splitter.split_documents(documents = datapdf)
```

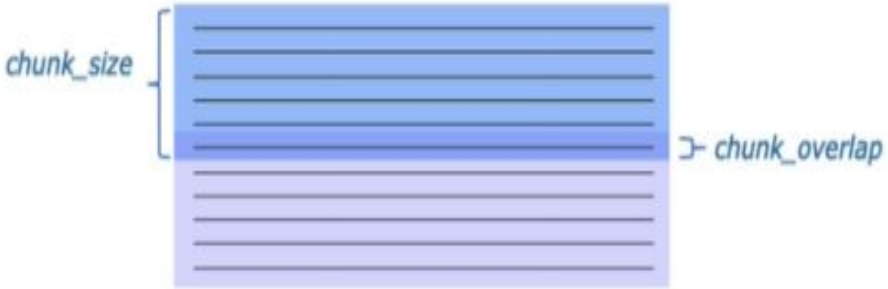

Bases de Datos Vectorial

Una base de datos vectorial es un tipo de base de datos que indexa y almacena embeddings (vectores)
para una recuperación rápida y búsqueda de similitudes, con capacidades como operaciones CRUD,
filtrado de metadatos y escalado horizontal.

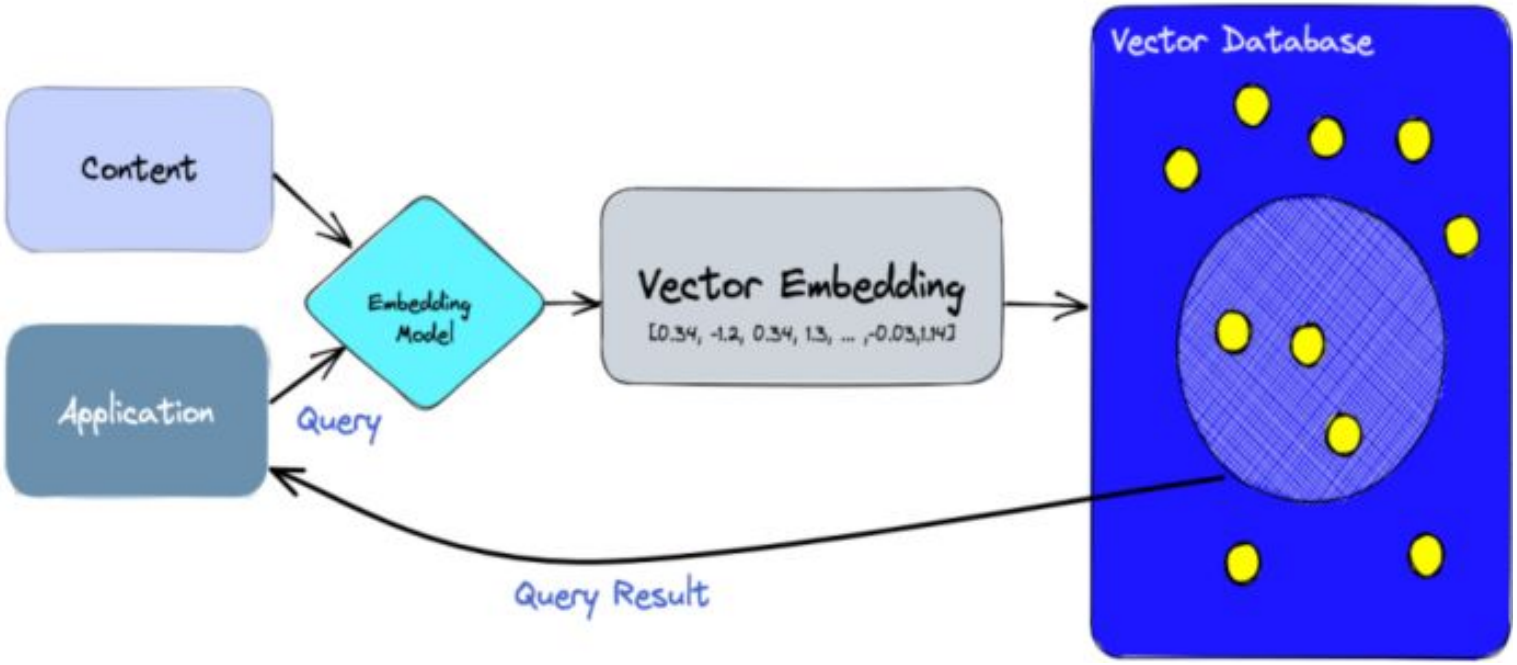

Bases de Datos Vectorial Pinecone

Pinecone es una base de datos vectorial (Saas) que facilita el almacenamiento y la recuperación de datos para su uso en aplicaciones Gen AI, como chatbots, sistemas de recomendación, RAG y motores de búsqueda.

Características:

- Bajo costo operativo : Existe una capa gratuita para usar Pinecone.
- Escalado sin tiempo de inactividad.
- Totalmente gestionado : Puede aprovisionarse en AWS, Google Cloud yAzure.
- Seguridad : Cumple el GDPR, SOC2 Tipo II, HIPAA.

RAG

La recuperación de generación aumentada (RAG) es una técnica que nos permite mantener los modelos de lenguaje grande (LLM) actualizados consultando información de una base de conocimientos con datos de nuestra empresa (base de datos vectorial), reduciendo las alucinaciones y permitirnos citar la fuente original de la información que se utiliza en la respuesta por el LLM.

Ventajas:

- Reduce las alucionaciones
- Información actualizada
- Se cita la fuente
- No es necesario reentrenar el modelo

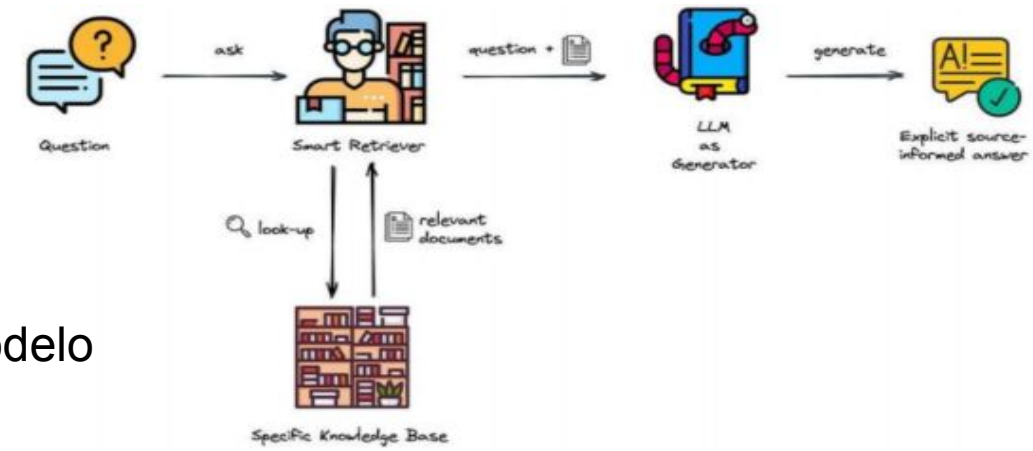

RAG (Recuperación de generación aumentada)

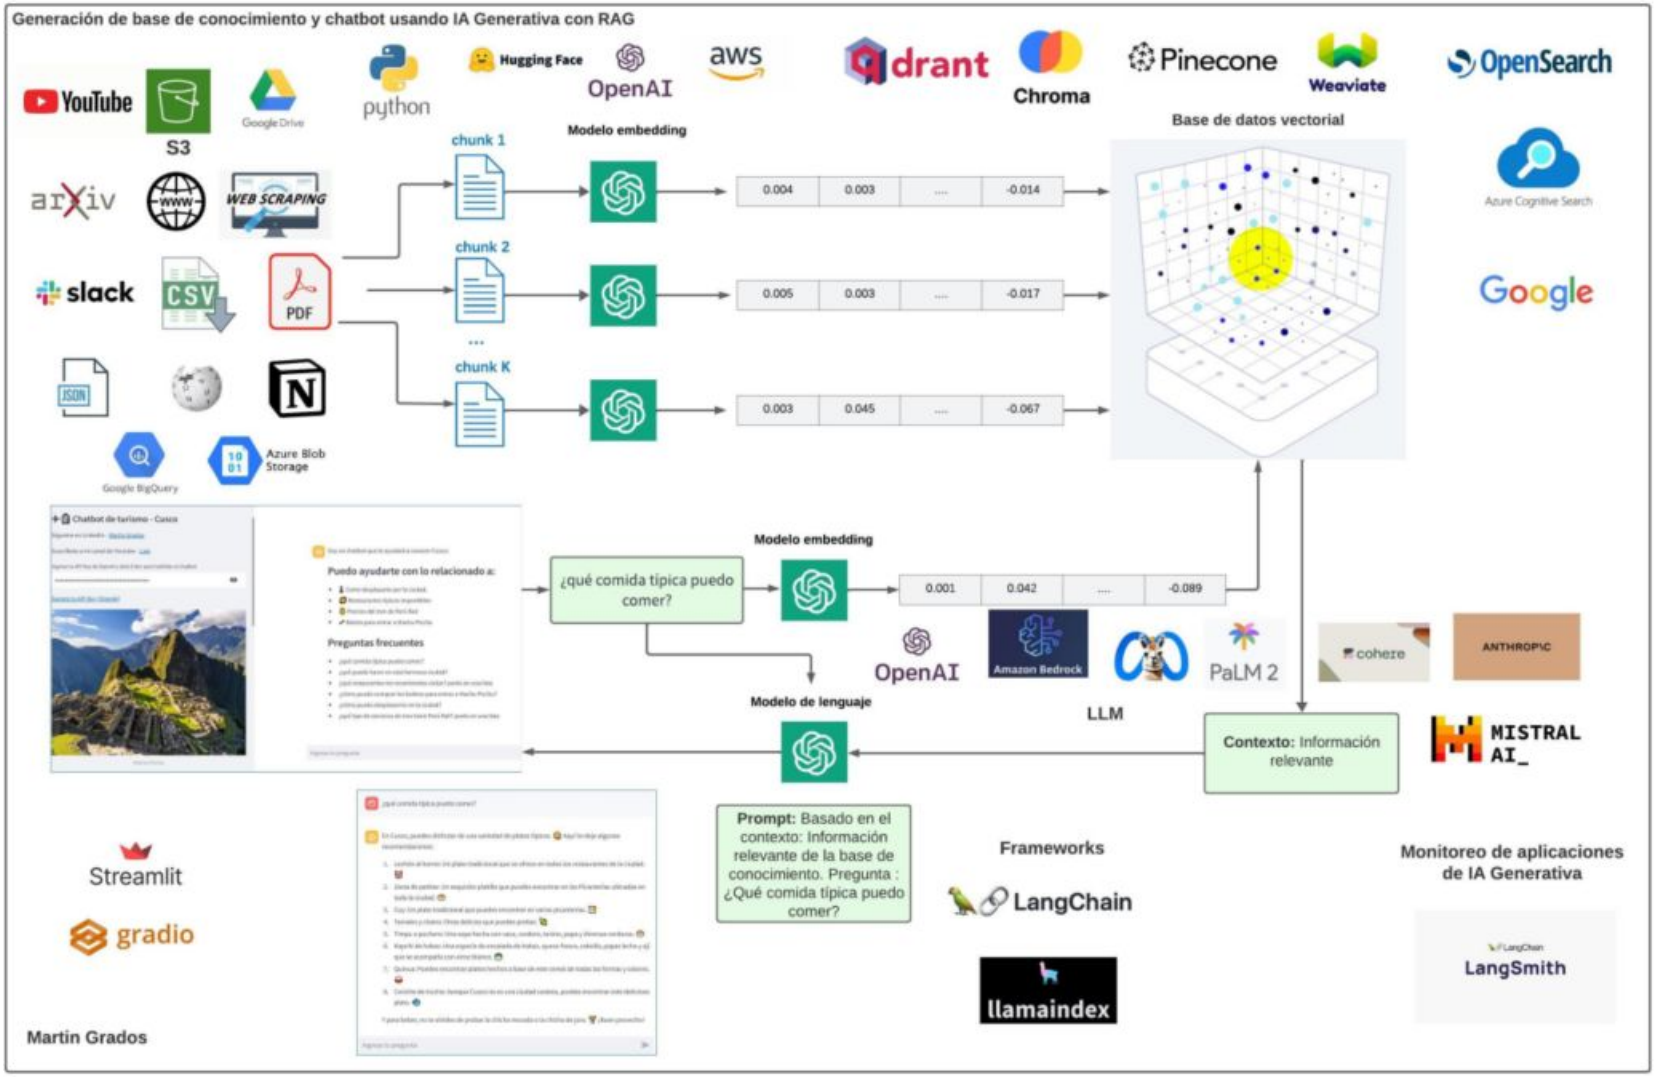

LLM

A codear!!!!!

Hugging Face

Hugging Face es una plataforma con más de 350000 modelos, 75000 conjuntos de datos y 150000 aplicaciones de demostración (Spaces), todas de código abierto y disponibles públicamente, en una plataforma en línea donde las personas pueden colaborar fácilmente y desarrollar ML juntas.
Funciona como un lugar donde cualquiera puede explorar, experimentar, colaborar y desarrollar tecnología con Machine Learning e IA Generativa.

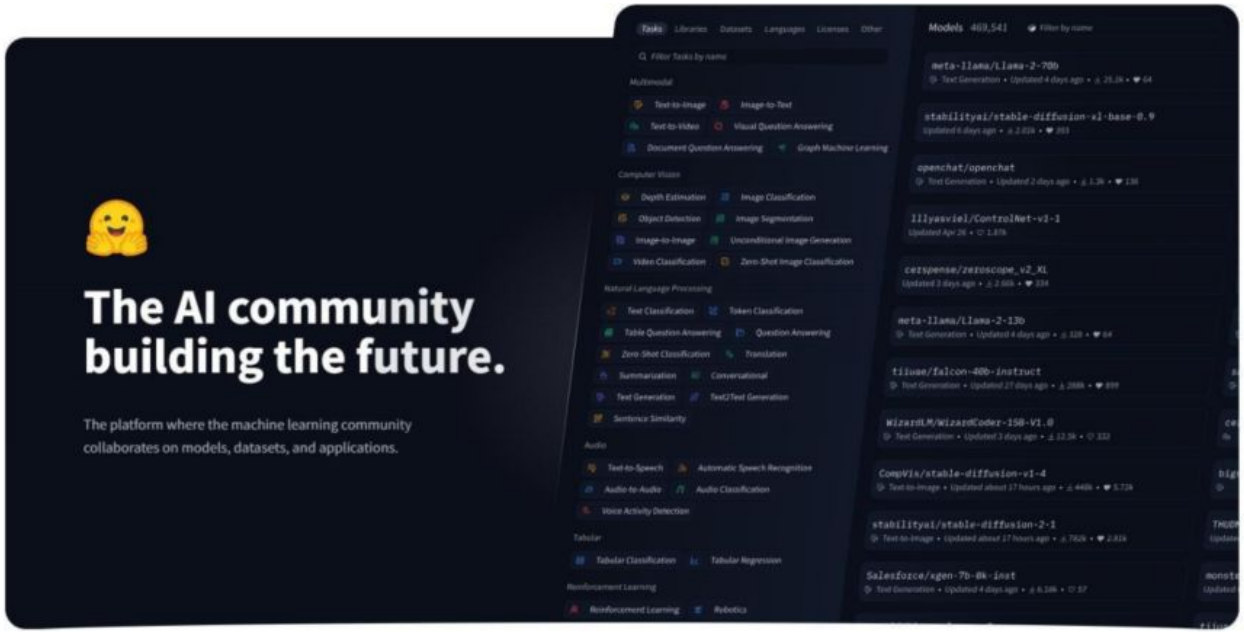

GRACIAS